

עיבוד שפה טבעית - תרגיל בית 1

תיאור המשימה

בתרגיל זה תממשו מודל Maximum Entropy Markov Model (MEMM) לטובת תיוג חלקי דיבר (Part of Speech Tagging), כפי שנלמד בהרצאה 3.

המימוש יתבצע ב-Python 3. ההגשה היא יחידנית.

תידרשו לממש ולאמן שני מודלים, **מודל 1 (הגדול) ומודל 2 (הקטן)**, על קבצי הנתונים המצורפים ב-[data.zip](#).

מדד הדיוק (Accuracy) מתייחס לדיוק ברמת המילה (Word-level Accuracy).

מבנה הציון

סעיף	אחוז מהציון	תיאור
מימוש מודל 1	35%	מימוש מלא של מודל 1 ואימונו על <code>train1.wtag</code> . דיווח Accuracy על <code>test1.wtag</code> .
תחרות מודל 1	20%	Accuracy בתיוג קובץ התחרות <code>comp1.words</code> .
מימוש ותחרות מודל 2	20%	מימוש ואימון מודל 2 על <code>train2.wtag</code> . Accuracy בתיוג קובץ התחרות <code>comp2.words</code> .
הערכת מודל 2	5%	ניתוח והערכת ביצועי מודל 2 בדו"ח.
דו"ח הגשה	10%	כתיבת דו"ח תמציתי ועמידה מלאה בתנאי הפורמט.
אורך קוד	10%	תחרות על אורך קוד כולל.

קבצים מצורפים (data.zip)

קובץ	מודל	תיאור
train1.wtag	מודל 1 (גדול)	5000 משפטים מתויגים לאימון. פורמט: word_TAG.
test1.wtag	מודל 1 (גדול)	1000 משפטים מתויגים למבחן.
comp1.words	מודל 1 (גדול)	1000 משפטים לא מתויגים לתחרות. פורמט: word word
train2.wtag	מודל 2 (קטן)	250 משפטים מתויגים לאימון.
comp2.words	מודל 2 (קטן)	1000 משפטים לא מתויגים לתחרות.

הערה לגבי הפורמט: התיוגים משתמשים בסכימת Treebank Penn. דוגמה:

the_D dog_N barks_V ...

דרישות המודלים

מודל 1 (הגדול)

- אימון: על train1.wtag.
- מאפיינים (Features): חובה לממש את סט המאפיינים (f100-f107 Ratnaparkhi, 1996), בתוספת מאפיינים התופסים מספרים ומילים המכילות אותיות גדולות (Capital letters). מותר להוסיף מאפיינים נוספים.
- מגבלת גודל: המודל המאומן יכול 10,000 פרמטרים לכל היותר. אי עמידה בתנאי = ציון 0.
- מבחן: יש לבצע הסקה על test1.wtag ולדווח את ה-Accuracy.

מודל 2 (הקטן)

- אימון: על train2.wtag.
- מאפיינים: מותר להגדיר ולממש מאפיינים כרצונכם (כולל אלו מודל 1).
- מגבלת גודל: המודל המאומן יכול 500 פרמטרים לכל היותר. אי עמידה בתנאי = ציון 0.
- מבחן: אין קובץ מבחן ייעודי. יש לתאר בדו"ח כיצד התמודדתם עם הערכת ביצועי המודל על מיעוט נתונים.

תחרויות

בתרגיל זה קיימות מספר תחרויות שונות:

1. **תחרות דיוק (Accuracy) מודל 1:** דיוק התיג ברמת המילה (Word-level Accuracy) על קובץ התחרות `comp1.words`.
 2. **תחרות דיוק (Accuracy) מודל 2:** דיוק התיג ברמת המילה על קובץ התחרות `comp2.words`.
 3. **תחרות אורך קוד:** ציון זה יינתן על בסיס תחרות בין הסטודנטים על הקוד הקצר ביותר (ע"פ מספר שורות). קוד קריא ומתועד עדיין נדרש. שימו לב כי שורות ריקות ושורות של הערות לא נספרות באורך הקוד.
 4. **הערכת מודל 2 (בדו"ח):** ניתוח והערכת ביצועי מודל 2 בדו"ח. הציון יינתן על בסיס ההפרש בערך מוחלט בין ההערכה שלכם לבין ביצועי המודל בפועל.
- יש לבצע הסקה (Inference) על קבצי התחרות (`comp1.words`, `comp2.words`) ולכתוב את התוצאות לקבצים חדשים בפורמט `wtag`.

- **פלט נדרש:** עבור `the dog barks` . ופלט תיג `D N V` . יש ליצור את השורה:
`the_D dog_N barks_V _.`
- **שמות קבצי ההגשה:** `comp_m1_123456789.wtag` ו-`comp_m2_123456789.wtag`.
- יש לוודא התאמה מלאה בין סדר המשפטים בקובץ המקורי לקובץ הפלט.

סביבת עבודה וקוד

- **סביבה:** הפרויקט נדרש לרוץ על המכונה המסופקת.
- **חבילות מותרות:** `Standard Python`, `scipy`, `numpy`, `pandas`, `matplotlib`, `tqdm`.
- **שימוש ב-LBFGS:** מומלץ להשתמש במימוש LBFGS (לדוגמה, ב-`scipy`) לצורך אופטימיזציה, אך יש לספק לו את פונקציית המטרה והגרדיאנט.
- **קוד שסופק:**
 - `preprocessing.py`: כולל את `f100`. יש לממש את יתר המאפיינים הנדרשים.
 - `Optimization.py`: לא חובה לשנות (אך ניתן).
 - `Inference.py`: חובה לממש את פונקציית `memm_viterbi`.
 - `main.py`: מאמן מודל, שומר את המשקולות שלו ואת קבצי התחרות המתוייגים עבור המודל המאומן.
 - `submission_check.py`: יבדוק את תקינות ההגשה שלכם. יש להריצו מתיקיה בה נמצאים הקובץ `HW1_1ID.zip` והתיקיה `data`.
 - `generate_comp_tagged.py`: להרצת Inference בלבד על המודלים המאומנים ויצירת קבצי התחרות המתוייגים ע"י כל מודל.
- **חבילות אסורות:** מימוש Viterbi, מימוש MEMM, חבילות עיבוד טקסט כגון ספירת חזרות/N-גרמים.

דרישות הגשה

- **דו"ח קצר ותמציתי:** כחלק מהתחרות על מודל 2 אתם נדרשים לתאר בדו"ח קצר (ע"פ הדרישות המפורטות מטה) את הבחירות שלכם עבור מודל 2 שתגישו (איך נבחרו פרמטרים וכל שיפור אחר שתבחרו להכניס).
הערכת הדו"ח תתבצע ע"ב:
 - יצירתיות: בבחירת מאפיינים ובהתמודדות עם מיעוט נתונים.
 - כתיבה וניסוח: בהירות הדיווח בדו"ח.
 - קפדנות (Rigorousity): שימוש בשיטות הערכה נכונות.
 - חדשנות: רעיונות מקוריים ויישומם.
- דרישות פורמט:
 - עד עמוד אחד בגודל A4
 - שוליים סטנדרטיים - 2.54 ס"מ בכל הצדדים
 - פורמט של עמודה אחת
 - פונט אריאל בגודל 10
 - מרווח סטנדרטי בין שורות (1.15)
 - מרווח של שורה ריקה בודדת בין פסקאות
 - כל תמונה צריכה להיות במרכז הדף, בלי wrap text around וחייבות להיות כתוביות (caption) מתחת לתמונה
 - טקסט בתוך תמונות (מקראים, כותרות וכו') חייב להיות בגודל לפחות 9 pt. אם צריך לעשות זום מעל 100% כדי לקרוא את הטקסט בתמונה, היא לא תחשב.
 - שם הקובץ: `report_123456789.pdf` המכיל הסברים תמציתיים, דיווח וניתוח תוצאות.
 - **תוכן חובה:** שם מחבר ות"ז, דיווח הערכת ביצועים למודל 2, הסבר על בחירת הפרמטרים, המאפיינים והשיפורים הסופיים בשני המודלים.
- ההגשה תהיה בקובץ `HW1_123456789.zip`.
- **קבצי הקוד:** קוד מתועד וקריא.
- **קבצי התחרות המתיגים:** `comp_m1_123456789.wtag` ו-`comp_m2_123456789.wtag`.
- **המודלים המאומנים:** שמורים בתיקיה `trained_models` בשמות `weights_1.pkl` ו-`weights_2.pkl`.
- **ממשק שחזור:** הקוד והמודלים המאומנים חייבים לאפשר שחזור זהה של קבצי התחרות.

שימו לב: **חוסר התאמה בפורמט הקבצים פירושו ציון 0.**

למען הסר ספק - מצורף לכם קובץ הגשה לדוגמה המכיל בדיוק את מבנה הקבצים שצריך להופיע ב-`zip` הסופי שלכם.

העתקות: חל איסור מוחלט על העברת קוד בין סטודנטים. מותר להשתמש בכלי AI, אך הקוד הוא באחריותכם ואסור להעביר את הפרומפטים או את קטעי הקוד שנוצרו על ידי AI.

הוראות הרצה לאתחול סביבת עבודה ויצירת קבצי הגשה:

None

```
1. run `bash init.sh`
2. Exit terminal and open new one
3. uv run python code/main.py --sid 000000000 --model 1
3. uv run python code/main.py --sid 000000000 --model 2
4. Create report pdf report_000000000.pdf
4. zip HW1_000000000.zip -r code/ -r trained_models/
comp_m1_000000000.wtag comp_m2_000000000.wtag report_000000000.pdf
5. uv run submission_check.py --sid 000000000
Running the defaults should give you:
Model 1: 3062 features
Model 2: 664 features
ERROR: exceeds the limit of 500 features.
Model 1 competition file: OK (1000 sentences).
Model 2 competition file: OK (1000 sentences).
```

Please fix the issues above before submitting.

```
6. If you add threshold 10 to main for both models:
uv run python code/main.py --sid 000000000 --model 1 --threshold 10
uv run python code/main.py --sid 000000000 --model 2 --threshold 10
Then rerun zipping and submission check you should see:
Model 1: 1561 features
Model 2: 75 features
Model 1 competition file: OK (1000 sentences).
Model 2 competition file: OK (1000 sentences).
```

All checks passed – it looks like you are ready to submit!